

RSNA Knee Abnormality Detection

Kaggle yarışması · Proje yol haritası ve yöntem rehberi

Görev	Diz MR çalışması başına 12 klinik bulgunun olasılık tahmini
Metrik	Macro-averaged ROC-AUC (12 hedefin ağırlıksız ortalaması)
Veri	819.640 DICOM dosyası · 569,76 GB · ~5.000+ eğitim study'si · 12 dilde radyoloji raporu
Test seti	~1.300 study · rapor metni verilmez
Format	Code competition · Kaggle Notebook · ≤9 saat · internet kapalı
Deadline	22 Ekim 2026 (entry/merger: 15 Ekim)
Ödül	\$77.000 (ana leaderboard \$59.000 + efficiency track \$18.000)
Önceliğimiz	Ana leaderboard · efficiency track öncelikli değil

Hedeflenen 12 bulgu

Etiket	Türkçe karşılığı	Etiket	Türkçe karşılığı
ACL	Ön çapraz bağ yaralanması	PF OA	Patellofemoral osteoartrit
MCL	İç yan bağ yaralanması	Effusion	Eklem efüzyonu (sıvı birikimi)
Medial Meniscus	İç menisküs yırtığı	Synovitis	Sinovyal zar iltihabı
Lateral Meniscus	Dış menisküs yırtığı	Baker's	Baker kisti
Medial OA	Medial kompartman osteoartriti	Contusion	Kemik kontüzyonu / ödem
Lateral OA	Lateral kompartman osteoartriti	Fracture	Kırık

Metriğin en önemli sonucu

Macro ortalama, her etiketi **eşit** ağırlıklandırır. Yani nadir bir bulguda (örn. Fracture) AUC 0,5'e düşerse, sık bulgulardaki başarı bunu telafi etmez. En zayıf etiketi iyileştirmek, en yüksek getirili işlerden biridir.

1. Bu yarışmayı zorlaştıran şey ne?

Bu bir “veriyi al, modeli eğit” yarışması değil. Asıl zorluk, elimizdeki verinin eksik ve gürültülü olması. Aşağıdaki beş problem, model mimarisinden daha belirleyici olma ihtimali yüksek olan problemler.

1.1 Zayıf etiketler — en kritik problem

Yarışmanın resmi veri açıklamasında açıkça yazıyor: eğitim study'lerinin **sadece küçük bir kısmı** doğrulanmış (gold) etikete sahip. Geri kalanın etiketlerini, verilen radyoloji raporlarından **bizim çıkarmamız** bekleniyor.

Yani elimizde iki kalite katmanı olacak: küçük ama güvenilir **gold** küme, ve büyük ama gürültülü **weak (zayıf)** küme. Bir öğrenciyi düşünün: elinde cevap anahtarı olan 50 soru var, ama 5.000 sorunun cevabını kendi tahmin etmesi gerekiyor. Tahminleri ne kadar iyi olursa, öğrendiği o kadar doğru olur.

Altın kural

Gold alt kümeyi **asla** weak-label üretiminde kullanma. Onu sadece doğrulama (validation) için sakla. Aksi halde ürettiğin etiketlerin ne kadar iyi olduğunu ölçecek tarafsız bir referansın kalmaz.

1.2 Site / scanner sızıntısı

Veri 19'dan fazla merkezden, 5 kitudan geliyor — farklı MR cihazları, farklı protokoller. Risk şu: model, “bu görüntü hangi hastaneden geldi”yi öğrenip bunu bir kısayol olarak kullanabilir. Eğer belirli bir merkez daha çok ağır vaka görüyorsa, model hastalığı değil hastaneyi tanıyarak yüksek skor alır — ve test setinde çöker.

Çözüm: Fold'ları rastgele değil, merkeze/hastaya göre **gruplayarak** böl (GroupKFold). Böylece bir merkezin verisi hem eğitimde hem doğrulamada yer almaz.

Komplikasyon: Veride doğrudan bir “merkez” sütunu yok. DICOM metadata'daki üretici/cihaz/manyetik alan alanları veya rapor dili bir vekil (proxy) olarak kullanılabilir — bunu Faz 0'da envanterleyeceğiz.

1.3 DICOM teknik varyasyonu

Intensiteler, oryantasyonlar ve çözünürlükler seri-seri değişiyor. Dört farklı sıkıştırma formatı (transfer syntax) var. Metadata gizlilik için 86 alana budanmış. MR'da, BT'deki gibi sabit bir birim (Hounsfield) yok — her seri kendi ölçeğinde. Bu yüzden normalizasyon zorunlu.

1.4 Dağılım kayması

Resmi uyarı: bulguların görülme sıklığının eğitim / public leaderboard / private leaderboard arasında aynı olacağı **garanti edilmiyor**. Public leaderboard'a aşırı uyum sağlamak (overfitting) riskli — final seçimde kendi CV skoruna da ağırlık ver.

1.5 Çok dillilik

Raporlar 12 dilde. Tek dilli veya basit anahtar kelime tabanlı bir etiket çıkarımı verinin büyük kısmını kaçıır. Ayrıca radyoloji raporlarında olumsuzlama kritik: “yırtık izlenmedi” ile “yırtık mevcut” cümleleri neredeyse aynı kelimeleri içerir ama tam zıt anlama gelir.

2. Çözüm mimarisi: Weak-label pipeline

Bu projenin kalbi burası. Basit regex'in yetmediği yerde, dört katmanlı bir sistem kuruyoruz.

Katman	Ne yapar	Neden
1. LLM çıkarımı	Çok dilli açık kaynak LLM (Qwen2.5 / Llama-3.1) her raporu okur, 12 bulgunun her biri için present / absent / uncertain + güven skoru üretir. JSON çıktı.	Doğal dil anlama, 12 dildeki ifade çeşitliliğini ve olumsuzlamayı ayrı bir modül kurmadan yakalar.
2. Distillation	LLM çıktısı + gold veriyle XLM-RoBERTa fine-tune edilir; 12 etiketli multi-label sınıflandırıcı.	LLM'i her seferinde çalıştırmak yavaş. Bu hızlı, tekrarlanabilir ve LLM gürültüsünü bir miktar filtreler.
3. Doğrulama	Gold alt kümede K-fold ile per-label precision / recall / F1 / AUC tablosu.	Hangi bulgular için ürettiğimiz etiketlere güvenebileceğimizi nicel olarak gösterir. Bu tablo bir sonraki katmanı belirler.
4. Soft label	Sert 0/1 yerine güven ağırlıklı yumuşak hedefler; gold örneklerle yüksek, belirsizlere düşük ağırlık.	Gürültülü etiketin modeli yanlış yöne çekmesini sınırlar.

Neden basit regex yetmez?

“No evidence of meniscal tear” cümlesinde “tear” kelimesi geçiyor ama bulgu **yok**. Bunu 12 dilde, her dilin kendi olumsuzlama yapısıyla regex'le çözmek pratikte imkânsız. Dil modelinin doğal dil anlama yeteneği tam da bu noktada devreye giriyor.

3. Görüntü modeli mimarisi

Bir study'de birden fazla seri (farklı düzlem ve sekans), her seride 20-45 kesit var. Bunu tek bir tahmine indirmek için üç katmanlı bir yapı kuruyoruz.

Aşama	Ne yapılır	Neden böyle
2.5D temsil	Merkez kesit $\pm$ komşu kesitler kanal olarak yığılır (örn. 5 kanal), 2D CNN'e verilir.	Tam 3D CNN pahalı, tek kesit bağımsız. 2.5D ikisinin ortası — komşu kesitlerden gelen derinlik bilgisini taşır, maliyeti düşük tutar.
Ortak backbone	Seçilen tüm seriler aynı ağırlıklı bir backbone'dan geçer (EfficientNet-B0 → DINOv2-small).	Ağırlık paylaşımı parametre sayısını düşürür, her seriden öğrenileni ortaklaştırır.
Agregasyon	Seri embedding'leri attention pooling ile study embedding'ine indirilir.	Mean pooling tüm serileri eşitler. Attention, “menisküs için sagittal, MCL için coronal daha önemli”yi modelin kendi öğrenmesini sağlar.
Çıkış	12 bağımsız sigmoid (multi-label, softmax değil).	Bir dizde aynı anda birden fazla bulgu olabilir — bunlar birbirini dışlamaz.

Seri seçimi metadata güdümlüdür. train_series.csv her seri için üç bilgi veriyor: düzlem (sagittal/coronal/axial), sıvı duyarlılığı ve yağ baskılama. Bunlar hangi bulgu için hangi seriye bakmak gerektiğini söyler — efüzyon ve ödem için sıvı duyarlı seriler, MCL için coronal, patellofemoral OA için axial. Bu bilgiyi hem seri seçiminde hem de modele ek girdi olarak kullanıyoruz.

4. Fazlar ve zaman planı

Bugün 6 Eylül 2026 · final deadline 22 Ekim 2026 · **kalan süre ~6,5 hafta.**

Faz	Başlık	İçerik
Faz 0 2-3 gün	Ortam ve DICOM temelleri	Transfer syntax doğrulama · 86 allowlisted tag envanteri · kesit sıralama · intensite normalizasyonu · laterality mirror · 2.5D stack · görsel doğrulama
Faz 1 Hafta 1-2	EDA + weak-label pipeline	Gold/etiketsiz oranı · dil dağılımı · per-label denge · ko-okürans · 4 katmanlı weak-label sistemi · gruplu fold stratejisi · sızıntı ölçümü
Faz 2 Hafta 2-3	Baseline + ilk submission	Ön işlenmiş Kaggle Dataset (570 GB → birkaç GB) · EfficientNet-B0 2.5D baseline · checkpoint/resume'lu eğitim · internet kapalı submission testi
Faz 3 Hafta 3-4	Model iyileştirme	5-fold tam eğitim · attention pooling · metadata enjeksiyonu · multi-view füzyon · backbone ablation (B0 → ConvNeXt → DINOv2) · loss ve çözünürlük ablation
Faz 4 Hafta 5	Ensemble ve ince ayar	Fold + mimari ensemble · rank averaging · per-label stacking · en zayıf etikete odaklı iyileştirme · runtime kontrolü
Faz 5 15-22 Ekim	Toparlama ve final	Final 2 submission seçimi (CV + LB dengeli) · kod temizliği · ağırlıkların Kaggle Dataset olarak yayını · format ve süre doğrulaması

Kritik tarihler

Tarih	Ne oluyor
15 Ekim 2026	Entry deadline — kuralların kabul edilmiş olması gerekiyor. Aynı zamanda takım birleşme son tarihi.
22 Ekim 2026	Final submission deadline. Bu tarihten sonra hiçbir gönderim kabul edilmiyor.
5 Kasım 2026	Ödül alınırsa: eğitim kodu, video ve metod açıklaması teslimi.

5. Asla feda edilmeyecekler

Zaman daralırsa bazı ablation'lardan vazgeçilebilir. Ama aşağıdakiler pazarlık konusu değil — her biri, atlanırsa tüm çalışmayı geçersiz kılacak adımlar.

DICOM tag envanteri (Faz 0.4)

Hangi metadata alanlarının gerçekten mevcut olduğunu bilmeden fold stratejisi kurulamaz. Site proxy'sinin temeli budur.

Gruplu fold (GroupKFold)

Rastgele split, scanner ezberlemesini gizler ve CV skorunu yapay olarak şişirir. Sonra private leaderboard'da gerçek performans ortaya çıkar — çok geç olarak.

Sadece gold üzerinde validation

Weak-label üzerinde doğrulama yapmak, weak-labeler'ın hatalarını “doğru” saymak demektir. Kendi kendini kandırmanın en hızlı yolu.

Internet kapalı submission testi (Faz 2.15)

Submission notebook'unda pip install çalışmaz, model ağırlıkları indirilemez. Bunu son haftaya bırakmak, en yaygın son dakika felaketidir. Erken test et.

Weak-label doğrulama tablosu (Faz 1.10)

Hangi etikete ne kadar güvenilebileceğini bilmeden ağırlıklandırma yapılamaz.

6. Teşhis kontrolleri

Sessiz başarısızlıkları erken yakalamak için her eğitim koşusunda bakılacaklar:

- **Tahmin dağılımı çöküşü:** Model tüm örneklerle neredeyse aynı skoru veriyorsa (per-label std < 0,05), gerçekte ayırt edici bir şey öğrenmemiş, sadece taban oranı ezberlemiş demektir.
- **Gruplu vs rastgele fold farkı:** İkisi arasındaki uçurum, site sızıntısının büyüklüğünü ölçer. Fark ne kadar büyükse gruplu fold o kadar zorunlu.
- **CV ile LB tutarlılığı:** CV yükselirken LB düşüyorsa, ya fold stratejisi ya da validation kümesi hatalı.
- **Submission sanity check:** Sütun isimleri birebir doğru mu, satır sayısı test study sayısı ile eşleşiyor mu, NaN var mı, tüm değerler [0,1] aralığında mı?

7. Teknoloji yığını

Alan	Araç	Not
Framework	PyTorch	Medikal görüntüleme ekosisteminin standardı
DICOM okuma	pydicom + pylibjpeg / gdcmm	Karışık transfer syntax'lar için plugin şart
Görüntü transform	MONAI	Medikal görüntü için hazır augmentation ve normalizasyon
Vision backbone	timm	EfficientNet-B0 → ConvNeXt-tiny → DINOv2-small
Karışık hassasiyet	torch.cuda.amp	Kaggle GPU süresi ve belleği için pratikte zorunlu

Alan	Araç	Not
Metrik	torchmetrics / scikit-learn	Per-label + macro ROC-AUC
Weak-label (LLM)	HF transformers + Qwen2.5 / Llama-3.1	Çok dilli yapılandırılmış çıkarım
Weak-label (distill)	XLM-RoBERTa	Hızlı, tekrarlanabilir etiketleyici
Dil tespiti	fasttext lid.176 / langdetect	Dil dağılımı + site proxy adayı
Fold	sklearn GroupKFold	Site sızıntısını önlemek
Deney takibi	EXPERIMENTS.md / W&B;	İki kişi paralel çalışıyor — kayıt şart

8. Compute stratejisi

Yerel makinede GPU ve disk yok. 570 GB'lık veri seti **hiçbir zaman indirilmiyor** — Kaggle Notebook'ta zaten mount edilmiş halde geliyor.

İş	Nerede	Neden
Kod yazma, mantık	Claude Code + Colab	GPU gerekmez
EDA (CSV analizleri)	Colab (CPU)	CSV'ler birkaç MB, CPU yeterli
DICOM prototipleme	Kaggle Notebook	Veri orada, indirme yok
Model eğitimi	Kaggle (birincil) → Colab / Lightning	Ücretsiz GPU kotası + ek kota
Weak-label LLM inference	Colab / Kaggle GPU	~5.000 kısa rapor, batch inference
Final submission	Kaggle Notebook (zorunlu)	≤9 saat, internet kapalı

Ön işlenmiş dataset stratejisi

570 GB ham DICOM'u her oturumda yeniden çözmek zaman israfı. Bir kere işleyip (gerekli kesitler → 256px → .npy) sonucu private bir Kaggle Dataset olarak yayınla. Bu, veriyi birkaç GB seviyesine indirir ve her yeni oturumda hazır veriden başlamanı sağlar.

Bu yol haritası, projenin genel görünümünü takip etmek içindir. Claude Code'a verilecek teknik detaylar ayrı dosyalarda: PROJECT_OVERVIEW.md (problem ve kurallar), ARCHITECTURE.md (teknik mimari), PHASES.md (görev listesi).